

МОДИФИКАЦИЯ ФУНКЦИОНАЛА ОШИБКИ В ЗАДАЧАХ НЕЛИНЕЙНОЙ РЕГРЕССИИ ДЛЯ УЧЕТА ПОГРЕШНОСТИ В ИЗМЕРЯЕМЫХ ДАННЫХ

Г. И. Рудой

1 Введение

В ряде экспериментальных приложений возникает задача нахождения оптимальных коэффициентов ω некоторой регрессионной модели f , представленной в виде аналитической формулы, по набору экспериментальных данных. Для этого в предположении о нормальном распределении регрессионных остатков строится функционал, являющийся суммой квадратов отклонений экспериментальных точек y_i от регрессионной кривой: $\sum_i (y_i - f(x_i, \omega))^2$. Для численного решения этой задачи широко применяется алгоритм Левенберга-Марквардта [1].

Однако, данный функционал построен и статистически обоснован в предположении о точно измеренных независимых переменных и гомоскедастичности ошибок измерения зависимой переменной. Иными словами, рассматриваются только ошибки измерения зависимой переменной, для которых дисперсия соответствующего распределения принимается одинаковой.

В значительной части естественнонаучных приложений это предположение не выполняется. Например, в задаче нахождения дисперсионной зависимости прозрачного полимера (то есть, зависимости коэффициента преломления n от длины волны λ) [2] погрешности измерения различных физических параметров, вообще говоря, различны. Так, например, если для измерения длины волны λ используется дифракционная решетка, то постоянной является относительная погрешность определения длины волны $\frac{\sigma_{\lambda_i}}{\lambda_i} \approx \text{const}$, и, следовательно, погрешность определения длины волны зависит от самой длины волны.

Таким образом, возникает задача поиска оптимальных коэффициентов регрессионной формулы с учетом отличающихся погрешностей различных экспериментальных точек. Для некоторых частных случаев эта задача уже была решена: например, в работе [3] вводится предположение, что зависимые переменные y_i измеряются неточно, и каждая переменная y_i имеет свою собственную погрешность измерения σ_{y_i} .

В настоящей работе рассмотрена более общая ситуация, в которой независимые переменные также определяются неточно в процессе эксперимента, и каждая переменная имеет свою собственную погрешность измерения. При этом рассматривается случай нелинейной регрессионной зависимости, в отличие от, например, [4], изучающей линейную регрессионную модель.

Предлагается модифицированный функционал качества, учитывающий погрешности как зависимых, так и независимых переменных в наиболее общем виде, и рассматривается соответствующим образом модифицированный алгоритм Левенберга-Марквардта, предназначенный для оптимизации этого функционала и опирающийся на классический алгоритм Левенберга-Марквардта (в дальнейшем будем называть их мАЛМ и АЛМ соответственно). Доказывается сходимость модифицированного алгоритма и приводятся результаты на экспериментальных данных по измерению параметров усиливающей среды лазерного излучателя.

2 Постановка задачи

Дана обучающая выборка $D = \{\mathbf{x}_i, y_i\} | i \in \{1, \dots, \ell\}, \mathbf{x}_i \in \mathbb{R}^m, y_i \in \mathbb{R}$. Для каждой зависимой переменной переменной y_i известно стандартное отклонение ошибки ее измерения σ_{y_i} , а для соответствующего вектора независимых переменных \mathbf{x}_i аналогично известны стандартные отклонения его компонент $\sigma_{x_{ij}} | j \in \{1, \dots, m\}$. Пусть, кроме того, дана некоторая регрессионная модель $y = f(\mathbf{x}, \boldsymbol{\omega})$, параметризованная вектором $\boldsymbol{\omega}$.

Для удобства введем вектор, составленный из ошибок измерений зависимых переменных σ_{y_i} :

$$\boldsymbol{\sigma}_y = \{\sigma_{y_1}, \dots, \sigma_{y_\ell}\}.$$

Аналогично введем матрицу, составленную из ошибок измерений независимых переменных $\sigma_{x_{ij}}$:

$$\Sigma_x = \|\sigma_{x_{ij}}\| | i \in \{1, \dots, \ell\}, j \in \{1, \dots, m\}.$$

Требуется построить функционал ошибки $S(\boldsymbol{\omega})$ вектора параметров $\boldsymbol{\omega}$ модели f , учитывающий ошибки измерений σ_{y_i} и $\sigma_{x_{ij}}$:

$$S(\boldsymbol{\omega}) = S(\boldsymbol{\omega}, \boldsymbol{\sigma}_y, \Sigma_x), \quad (1)$$

и, кроме того, найти вектор параметров $\boldsymbol{\omega}$, минимизирующий функционал (1):

$$\hat{\boldsymbol{\omega}} = \arg \min_{\boldsymbol{\omega}} S(\boldsymbol{\omega}) \quad (2)$$

3 Модифицированный функционал качества

Воспользуемся следующим естественным качественным физическим соображением: чем больше погрешность определения зависимой и независимых переменных для некоторой экспериментальной точки, тем меньше соответствующий регрессионный остаток должен учитываться при оптимизации параметров модели. Кроме того, эта зависимость линейна: если, например, $\sigma_{x_{i1}} = k\sigma_{x_{i2}}$, т. е. если погрешность измерения первой компоненты признаков описания в k раз больше погрешности второй компоненты, то расстояние от экспериментально измеренной точки (\mathbf{x}_i, y_i) до регрессионной зависимости по оси, соответствующей первой компоненте, имеет в k раз меньший вес, чем то же расстояние по оси, соответствующей второй компоненте. Можно заметить, что это эквивалентно некоторому локальному растяжению пространства в окрестности точки (\mathbf{x}_i, y_i) .

Рассмотрим для простоты изложения случай одной независимой переменной: $x \in \mathbb{R}$. Введем следующее определение расстояния $\rho(x, i)$ от точки (x_i, y_i) из обучающей выборки до некоторой точки $(x, f(x, \boldsymbol{\omega}))$ на кривой, описываемой регрессионной моделью:

$$\rho^2(x, i) = \frac{(x_i - x)^2}{\sigma_{x_i}^2} + \frac{(y_i - y)^2}{\sigma_{y_i}^2}, \quad (3)$$

где $y = f(x, \boldsymbol{\omega})$.

Непосредственное точное определение расстояния представляется отдельной сложной вычислительной задачей, однако, в подавляющем большинстве практических приложений регрессионные зависимости достаточно гладкие, а погрешности измерения достаточно малы. Пользуясь этим, линеаризуем $f(x, \boldsymbol{\omega})$ в окрестности точки x_i :

$$f(x, \boldsymbol{\omega}) = f(x_i, \boldsymbol{\omega}) + (x - x_i) \frac{\partial f}{\partial x}(x_i, \boldsymbol{\omega}). \quad (4)$$

Введем для удобства обозначение $k = \frac{\partial f}{\partial x}(x_i, \omega)$.

Тогда расстояние (3) можно выразить через линейризованную функцию (4) следующим образом:

$$\rho^2(x, i) = \frac{(x_i - x)^2}{\sigma_{x_i}^2} + \frac{(y_i - f(x_i, \omega) - k(x - x_i))^2}{\sigma_{y_i}^2}. \quad (5)$$

Минимизируя это выражение, находим выражение для расстояния от точки (x_i, y_i) из обучающей выборки до линейризованной в ее окрестности экспериментальной зависимости:

$$\rho^2(x, i) = \frac{(y_i - f(x_i, \omega))^2}{\sigma_{y_i}^2 + k^2 \sigma_{x_i}^2}. \quad (6)$$

Аналогично можно получить выражение для случая, когда объекты в обучающей выборке имеют m независимых переменных ($\mathbf{x} \in \mathbb{R}^m$):

$$\rho^2(\mathbf{x}, i) = \frac{(y_i - f(\mathbf{x}_i, \omega))^2}{\sigma_{y_i}^2 + \sum_{j=1}^m \left(\frac{\partial f}{\partial x_j}(\mathbf{x}_i, \omega) \right)^2 \sigma_{x_{ij}}^2}.$$

Таким образом, функционал, минимизирующий сумму введенных согласно (3) расстояний, выглядит следующим образом:

$$S(\omega) = \sum_{i=1}^{\ell} \frac{(y_i - f(\mathbf{x}_i, \omega))^2}{\sigma_{y_i}^2 + \sum_{j=1}^m \left(\frac{\partial f}{\partial x_j}(\mathbf{x}_i, \omega) \right)^2 \sigma_{x_{ij}}^2}. \quad (7)$$

Отметим следующие наблюдения:

- Функционал (7) соответствует классической сумме квадратов регрессионных остатков при условии нормировки квадрата каждого остатка на сумму квадратов погрешности определения зависимой величины σ_{y_i} и произведения частной производной регрессионной модели по j -ой компоненте вектора независимых величин на погрешность определения соответствующей компоненты $\sigma_{x_{ij}}$.
- При прочих равных условиях в выражении для расстояния (6) и, соответственно, в функционале (7) с большим весом учитываются те точки, в которых производная регрессионной модели $\frac{\partial f}{\partial x_j}$ по соответствующей компоненте x_j больше, что соответствует соображениям здравого смысла: чем меньше наклон регрессионной зависимости в окрестности данной точки, тем меньше влияние неточного измерения соответствующей независимой переменной на значение регрессионной зависимости в этой точке.
- Кроме того, если все независимые переменные измерены точно, то есть, $\forall i, j : \sigma_{x_{ij}} = 0$, то предложенный функционал переходит в предложенный в [3]. Если же, кроме того, все зависимые переменные имеют одну и ту же погрешность, то предложенный функционал переходит в известную сумму квадратов регрессионных остатков с точностью до некоторого множителя σ_y , не влияющего на точки минимума функционала среднеквадратичной ошибки.

4 Модифицированный алгоритм Левенберга-Марквардта

Для минимизации функционала (7) предлагается следующий итеративный алгоритм, предназначенный для использования с уже имеющимися реализациями АЛМ ¹:

1. Выбирается некоторое начальное приближение вектора параметров ω .
2. Для каждой пары (\mathbf{x}_i, y_i) из обучающей выборки рассчитывается значение частной производной $\frac{\partial f}{\partial x}$ в точке (\mathbf{x}_i, ω) .
3. Каждое значение зависимой переменной y_i и значение функции $f(\mathbf{x}_i, \omega)$ нормируется на соответствующую величину

$$\sigma_{y_i}^2 + \sum_{j=1}^m \left(\frac{\partial f}{\partial x_j}(\mathbf{x}_i, \omega) \right)^2 \sigma_{x_{ij}}^2.$$

4. Выполняется итерация АЛМ для таким образом модифицированных значений функции f и зависимых переменных y_i , таким образом получается новое значение вектора ω .
5. Если критерий останова мАЛМ не достигнут, алгоритм продолжает выполнение с пункта 2.

Отметим следующее:

- Критерием останова мАЛМ могут служить обычные критерии вроде достижения некоторого числа итераций, нормы изменения вектора ω , и т. п.
- Если известно, что производная $\frac{\partial f}{\partial x}$ достаточно гладка в окрестности $(\mathbf{x}_i, \omega) \mid i \in \{1, \dots, \ell\}$, на шаге 4 алгоритма мАЛМ представляется разумным выполнить сразу несколько итераций классического АЛМ во избежание потенциально ресурсоемкого пересчета производных и перенормировки значений y_i и f .

Сходимость предложенного алгоритма можно показать, сведя его к классическому АЛМ. Для этого вместо объектов (\mathbf{x}_i, y_i) в обучающей выборке будем формально рассматривать объекты $(\tilde{\mathbf{x}}_i, \tilde{y}_i)$, где $\tilde{y}_i = 0$, а $\tilde{\mathbf{x}}_i$ — вектор \mathbf{x}_i с дополнительно приписанным к нему значением y_i . Примем

$$\tilde{f}(\tilde{\mathbf{x}}_i, \omega) = \frac{f(\mathbf{x}_i, \omega) - y_i}{\sqrt{\sigma_{y_i}^2 + \sum_{j=1}^m \left(\frac{\partial f}{\partial x_j}(\mathbf{x}_i, \omega) \right)^2 \sigma_{x_{ij}}^2}}.$$

Тогда минимизация функционала (7) возможна средствами классического АЛМ, так как легко видеть, что (7) в этом случае эквивалентен

$$S(\omega) = \sum_{i=1}^{\ell} (\tilde{y}_i - \tilde{f}(\tilde{\mathbf{x}}_i, \omega))^2.$$

Кроме того, при возможности выполнить аналитическое дифференцирование функции f , этот метод показывает еще один способ практической минимизации функционала (7) без постоянной корректировки значений y_i и f , как в предложенном выше алгоритме.

¹Предполагается, что реализация АЛМ «принимает на вход» массив значений y_i , функцию вычисления значения f в точках \mathbf{x}_i с вектором параметров ω , и критерий останова в виде числа итераций. Примером такой реализации, использовавшейся авторами, может служить [5].

5 Вычислительный эксперимент

В вычислительном эксперименте рассматриваются данные, полученные в ходе анализа зависимости интенсивности излучения I лазера от прозрачности его резонатора. Изучался лазер высокого давления (≈ 3 атм He , ≈ 60 Торр Ne , ≈ 20 Торр Ar) на $3p - 3s$ переходах неона (основной переход — 585 нм), возбуждаемый электронным пучком, что означает, что накачка однородна.

Пусть насыщающая переход интенсивность излучения — I_s , наблюдаемая интенсивность — I_l . В таком случае для безразмерной величины $y = \frac{I_l}{I_s}$ можно получить нелинейное уравнение [?]:

$$\alpha_0 L - \frac{1}{2} \ln R_0 = g_0 L \frac{1 + \sqrt{R_0}}{1 - \sqrt{R_0}} \frac{1}{y} \ln \left(1 + \frac{y^{\frac{1-\sqrt{R_0}}{1+\sqrt{R_0}}}}{1 + y^{\frac{2\sqrt{R_0}}{1-R_0}}} \right), \quad (8)$$

где α_0 — распределенные потери (например, на рассеяние света), g_0 — коэффициент усиления слабого сигнала, R_0 — прозрачность выходного зеркала лазера. Однородность накачки означает, что g_0 и α_0 одинаковы по всему объему с хорошей точностью.

Для достаточно больших R_0 , близких к единице, можно заменить $2\sqrt{R_0} \approx 1 + R_0$ в (8), получив выражение

$$y(R_0) = \gamma \frac{1 - R_0}{1 + R_0} \left(\frac{g_0}{\alpha_0 - \frac{1}{2} L \ln R_0} - 1 \right), \quad (9)$$

где γ — нормировочный коэффициент.

Длина активной среды $L = 150$ см, точность определения мощности лазера зафиксирована как относительная погрешность в 2% ($\sigma_y = 0.02y$), точность определения R_0 зафиксирована как абсолютная погрешность и составляет 0.01 см ($\sigma_{R_0} = 0.01$).

В ходе физических измерений получены значения $y(R_0)$, приведенные в таблице 1.

Таблица 1: Экспериментальные значения $y(R_0)$.

R_0	0.48	0.56	0.65	0.73	0.80	0.87	0.94
y	3.25	10.2	16.5	20.5	22.5	23.2	18.2

Таким образом, решается задача минимизации функционала (7) при $f(R_0, \omega) = y(R_0, \gamma, \alpha_0, g_0)$, то есть, вектор параметров ω состоит из трех компонент γ, α_0, g_0 . Предполагается, что указанные выше погрешности определяют дисперсию соответствующего распределения ошибок измерений: $\sigma_{y_i} = 0.02y_i$, $\sigma_{x_i} = 0.01$.

5.1 Оптимальные параметры модели

В таблице 2 приведены оптимальные значения параметров модели, а также соответствующие значения MSE, для модифицированного функционала (7). В таблице также приведены для сравнения соответствующие значения, получающиеся при минимизации классического функционала

$$S = \sum_{i=1}^{\ell} (y_i - f(x_i, \omega))^2, \quad (10)$$

а также относительная разность соответствующих величин.

Таблица 2: Оптимальные значения параметров модели.

	g_0	α_0	γ	MSE
(7)	$2.932 \cdot 10^{-3}$	$2.219 \cdot 10^{-4}$	99.2	0.282
(10)	$2.917 \cdot 10^{-3}$	$2.129 \cdot 10^{-4}$	101.5	0.183
Разность	$5.2 \cdot 10^{-3}$	$4.2 \cdot 10^{-2}$	$2.4 \cdot 10^{-2}$	0.54

5.2 Сходимость оптимальных параметров


Численно исследована зависимость сходимости параметров ω к параметрам ω_0 , получаемым минимизацией функционала (10).

Разумно предположить, что при увеличении погрешности измерения величины y при фиксированной погрешности измерения R_0 оптимальный вектор ω будет приближаться к ω_0 , так как тем более незначительным будет вклад ошибки измерения независимой переменной.


Рассматривается зависимость оптимальных коэффициентов g_0 , α_0 и γ от погрешности измерения y , задаваемой как $k\sigma_y = 0.02ky$, где k в одном эксперименте менялось от 1 до 10, а в другом — от 1 до 10^4 , в обоих случаях с шагом 0.1. Отметим, что при $k = 50$ характерная погрешность измерения величины y сопоставима с самой величиной y , а при больших значениях k превышает ее.

Результаты приведены на рис. 1 и 2 соответственно.


Видно, что для достаточно больших k оптимальные значения параметров ω существенно отличаются от ω_0 . Соответствующая зависимость имеет сложный характер с несколькими (как минимум, двумя) пересечениями с искомыми оптимальными значениями. Подробное исследование подобной зависимости является целью будущих работ.



(a) g_0




(b) α_0




(c) γ


Рис. 1: Зависимость оптимальных параметров от $\sigma_y = 0.02ky, k \in [1; 10]$.



(a) g_0



(b) α_0



(c) γ

Рис. 2: Зависимость оптимальных параметров от $\sigma_y = 0.02ky, k \in [1; 10000]$.

Список литературы

- [1] Marquardt, D. W.: *An algorithm for least-squares estimation of non-linear parameters*. Journal of the Society of Industrial and Applied Mathematics, 11(2):431–441, 1963.
- [2] Рудой, Г. И.: *О Возможности Применения Методов Монте-Карло В Анализе Нелинейных Регрессионных Моделей*. Сибирский Журнал Вычислительной Математики, 4, 2015.
- [3] Jukić, Dragan: *On nonlinear weighted least squares estimation of Bass diffusion model*. Applied mathematics and computation, 219(14):7891–7900, 2013.
- [4] Kiryati, Nahum и Bruckstein, Alfred M: *Heteroscedastic Hough transform (HtHT): An efficient method for robust line fitting in the ‘errors in the variables’ problem*. Computer Vision and Image Understanding, 78(1):69–83, 2000.
- [5] King, Davis E.: *Dlib-ml: A Machine Learning Toolkit*. Journal of Machine Learning Research, 10:1755–1758, 2009.